

ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIỀN TIẾN, CHẤT LƯỢNG CAO VÀ POHE



BÁO CÁO

MÔN: KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH
(AEP.TOKT1138.LS)

Thành viên (Nhóm 6):

Trương Lê Thanh Huyền (MSV: 11241046)

Đỗ Diệu Anh (MSV: 11244431)

Lê Thùy Anh (MSV: 11244797)

Nguyễn Thu Huyền (MSV: 11248017)

Hoa Mai Hương (MSV: 11244746)

Lớp: Kinh tế Quốc tế CLC 66C

Giảng viên: TS.Trần Đức Minh

Hanoi, May, 2026

MỤC LỤC

1. THU THẬP VÀ LÀM SẠCH DỮ LIỆU (DATA COLLECTING & CLEANING).....	1
2. KIỂM TRA VÀ HỢP NHẤT (DATA INTEGRATION).....	8
3. PHÂN TÍCH KHÁM PHÁ (EDA - EXPLORATORY DATA ANALYSIS).....	9
4. ĐÁNH GIÁ BẰNG BIỂU ĐỒ (VISUAL ANALYSIS).....	14
5. TỔNG KẾT VÀ ĐỀ XUẤT.....	25
5.1. Tổng hợp Insight.....	25
5.2 Giá trị thực tiễn.....	25
5.3 Hạn Chế.....	26
5.4 Đề xuất.....	27

1. THU THẬP VÀ LÀM SẠCH DỮ LIỆU (DATA COLLECTING & CLEANING)

```
from google.colab import drive
drive.mount('/content/drive')
```

Mounted at /content/drive

```
import pandas as pd
import numpy as np

# Đọc dataset từ Google Drive
path = '/content/drive/MyDrive/Colab Notebooks/data4/online_retail_II.xlsx'
df_raw = pd.read_excel(path)

# Tạo bản copy để xử lý dữ liệu
df = df_raw.copy()

print("Kích thước dữ liệu:", df.shape)
```

Kích thước dữ liệu: (525461, 8)

*Data Collection

- Nhóm sử dụng bộ dữ liệu Online Retail Dataset được tải từ Kaggle. Dataset này ghi lại các giao dịch bán lẻ trực tuyến của một doanh nghiệp trong giai đoạn 2009–2011, bao gồm các thông tin như mã hóa đơn (Invoice), mã sản phẩm (Stock Code), mô tả sản phẩm (Description), số lượng (Quantity), ngày giao dịch (InvoiceDate), giá bán (Price), mã khách hàng (Customer ID) và quốc gia (Country).

- Ngay khi tải dữ liệu về và thực hiện bước đọc dữ liệu vào môi trường phân tích bằng Python (Pandas), nhóm nhận thấy rằng dataset có quy mô khá lớn và chứa nhiều thông tin hữu ích. Tuy nhiên, giống như phần lớn dữ liệu thực tế trong kinh doanh, dữ liệu này chưa thể sử dụng ngay cho phân tích. Dataset vẫn tồn tại nhiều vấn đề phổ biến của dữ liệu thô (raw data) như:

- + Giá trị thiếu (missing values)
- + Khả năng xuất hiện dữ liệu trùng lặp
- + Sai định dạng kiểu dữ liệu
- + Các giao dịch bất thường hoặc không hợp lệ
- + Các giá trị cực đoan (outliers)

Do đó, trước khi tiến hành phân tích dữ liệu (EDA) hay xây dựng insight, nhóm cần thực hiện một bước quan trọng: Data Cleaning.

```
# Xem 5 dòng đầu của dataset
df.head()
```

	Invoice	StockCode	Description	Quantity	InvoiceDate	Price	Customer ID	Country
0	489434	85048	15CM CHRISTMAS GLASS BALL 20 LIGHTS	12	2009-12-01 07:45:00	6.95	13085.0	United Kingdom
1	489434	79323P	PINK CHERRY LIGHTS	12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom
2	489434	79323W	WHITE CHERRY LIGHTS	12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom
3	489434	22041	RECORD FRAME 7" SINGLE SIZE	48	2009-12-01 07:45:00	2.10	13085.0	United Kingdom
4	489434	21232	STRAWBERRY CERAMIC TRINKET BOX	24	2009-12-01 07:45:00	1.25	13085.0	United Kingdom

```
# Kiểm tra cấu trúc dữ liệu và kiểu dữ liệu
df.info()
```

```
# Thống kê các biến số trong dataset
df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 525461 entries, 0 to 525460
Data columns (total 8 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Invoice          525461 non-null object
1   StockCode        525461 non-null object
2   Description      522533 non-null object
3   Quantity         525461 non-null int64
4   InvoiceDate       525461 non-null datetime64[ns]
5   Price            525461 non-null float64
6   Customer ID     417534 non-null float64
7   Country          525461 non-null object
dtypes: datetime64[ns](1), float64(2), int64(1), object(4)
memory usage: 32.1+ MB
```

	Quantity	InvoiceDate	Price	Customer ID
count	525461.000000	525461	525461.000000	417534.000000
mean	10.337667	2010-06-28 11:37:36.845017856	4.688834	15360.645478
min	-9600.000000	2009-12-01 07:45:00	-53594.360000	12346.000000
25%	1.000000	2010-03-21 12:20:00	1.250000	13983.000000
50%	3.000000	2010-07-06 09:51:00	2.100000	15311.000000
75%	10.000000	2010-10-15 12:45:00	4.210000	16799.000000
max	19152.000000	2010-12-09 20:01:00	25111.090000	18287.000000
std	107.424110	NaN	146.126914	1680.811316

* Khám phá dữ liệu ban đầu (Initial Data Exploration)

- Trước khi xử lý dữ liệu, nhóm tiến hành khám phá dataset để hiểu rõ cấu trúc và đặc điểm của dữ liệu. Các hàm như:

- + head() để quan sát những dòng dữ liệu đầu tiên
- + info() để kiểm tra kiểu dữ liệu và số lượng giá trị thiếu
- + describe() để xem các thống kê mô tả cơ bản

được sử dụng trong bước này.

- Thông qua quá trình quan sát ban đầu, nhóm nhận thấy một số điểm đáng chú ý:

- + Dataset có nhiều cột thông tin khác nhau liên quan đến giao dịch bán hàng.
- + Một số cột chứa missing values, đặc biệt là cột Customer ID.
- + Một số biến số có thể chứa giá trị bất thường, ví dụ như số lượng sản phẩm (Quantity) hoặc giá bán (Price).
- + Một số biến cần được chuẩn hóa kiểu dữ liệu để phục vụ phân tích sau này.

- Việc dành thời gian khám phá dữ liệu ở bước đầu giúp nhóm hiểu rõ bản chất của dataset trước khi can thiệp vào dữ liệu, từ đó tránh các quyết định xử lý mang tính cảm tính. Đây là một bước quan trọng trong quy trình phân tích dữ liệu, vì các quyết định cleaning ở giai đoạn này sẽ ảnh hưởng trực tiếp đến kết quả phân tích phía sau.

```
# Kiểm tra tên cột và kiểu dữ liệu
print ("Danh sách các cột:")
print(df.columns)

print("kiểu dữ liệu:")
print(df.dtypes)
```

```
Danh sách các cột:
Index(['Invoice', 'StockCode', 'Description', 'Quantity', 'InvoiceDate',
       'Price', 'Customer ID', 'Country'],
      dtype='object')
kiểu dữ liệu:
Invoice           object
StockCode         object
Description       object
Quantity          int64
InvoiceDate       datetime64[ns]
Price             float64
Customer ID       float64
Country           object
dtype: object
```

*Kiểm tra tính nhất quán của dữ liệu (Data Consistency)

- Trong quá trình khám phá dữ liệu ban đầu, nhóm cũng tiến hành kiểm tra tính nhất quán của dataset bằng cách quan sát tên cột và kiểu dữ liệu của từng biến.
- Việc kiểm tra này giúp đảm bảo rằng:
 - + Các cột dữ liệu được lưu trữ đồng nhất
 - + Không tồn tại sự khác biệt về cấu trúc dữ liệu
 - + Các biến được định dạng phù hợp cho các bước phân tích tiếp theo
- Kết quả kiểm tra cho thấy dataset có cấu trúc ổn định và các cột dữ liệu được tổ chức nhất quán, giúp quá trình cleaning và phân tích được thực hiện thuận lợi hơn.

```
# Kiểm tra số lượng missing values
missing = df.isnull().sum()

print("Số lượng giá trị thiếu:")
print(missing)
```

```
Số lượng giá trị thiếu:
Invoice           0
StockCode         0
Description       2928
Quantity          0
InvoiceDate       0
Price             0
Customer ID      107927
Country           0
dtype: int64
```

```
# Xóa các dòng không có Customer ID
before_shape = df.shape

df = df.dropna(subset=['Customer ID'])

after_shape = df.shape

print("Trước khi xóa:", before_shape)
print("Sau khi xóa:", after_shape)
```

```
Trước khi xóa: (525461, 8)
Sau khi xóa: (417534, 8)
```

```
# Kiểm tra lại dữ liệu thiếu sau khi xử lý
print("Missing sau xử lý:")
print(df.isnull().sum())
```

```
Missing sau xử lý:
Invoice           0
StockCode         0
Description       0
Quantity          0
InvoiceDate       0
Price             0
Customer ID       0
Country           0
dtype: int64
```

*Xử lý giá trị thiếu (Missing Values)

- Sau khi kiểm tra chi tiết bằng phương thức isnull().sum(), nhóm nhận thấy cột Customer ID có một lượng giá trị thiếu tương đối lớn.

- Đây là một vấn đề quan trọng vì các phân tích phía sau của bài toán – đặc biệt là phân tích hành vi khách hàng – đều phụ thuộc vào việc xác định chính xác từng khách hàng. Nếu một giao dịch không có Customer ID, giao dịch đó sẽ không thể liên kết với bất kỳ khách hàng nào.

Ban đầu, nhóm đã cân nhắc việc imputation (điền giá trị thiếu) để giữ lại càng nhiều dữ liệu càng tốt. Tuy nhiên, khi xem xét bản chất của biến Customer ID, nhóm nhận ra rằng đây không phải là một biến có thể suy luận từ các biến khác, mà là một mã định danh duy nhất cho mỗi khách hàng.

- Việc điền giá trị giả định cho biến này sẽ dẫn đến hai vấn đề:

+ Có thể gán nhầm nhiều giao dịch vào cùng một khách hàng không tồn tại.

+ Làm sai lệch các phân tích về hành vi khách hàng như tần suất mua hàng hoặc tổng giá trị mua.

- Do đó, nhóm quyết định loại bỏ các dòng dữ liệu không có Customer ID. Mặc dù quyết định này làm giảm số lượng quan sát của dataset, nhưng đổi lại giúp đảm bảo rằng mọi giao dịch còn lại đều có thể liên kết với một khách hàng cụ thể, điều rất quan trọng cho các phân tích tiếp theo.

```
# Kiểm tra duplicated
dup = df.duplicated().sum()

print("Số dòng trùng:", dup)

if dup > 0:
    df = df.drop_duplicates()
    print("Đã xóa duplicate")
else:
    print("Không có duplicate nên không cần xử lý")
```

Số dòng trùng: 6771
Đã xóa duplicate

```
# Invoice bắt đầu bằng 'C' là đơn bị hủy
cancel = df['Invoice'].astype(str).str.startswith('C').sum()

print("Số đơn bị hủy:", cancel)
```

Số đơn bị hủy: 9816

```
# Xem dữ liệu các đơn bị hủy
fix = df[df['Invoice'].astype(str).str.startswith('C')]

print("Số dòng đơn bị hủy:", fix.shape)
fix.head()
```

Số dòng đơn bị hủy: (9816, 8)

	Invoice	StockCode	Description	Quantity	InvoiceDate	Price	Customer ID	Country
178	C489449	22087	PAPER BUNTING WHITE LACE	-12	2009-12-01 10:33:00	2.95	16321.0	Australia
179	C489449	85206A	CREAM FELT EASTER EGG BASKET	-6	2009-12-01 10:33:00	1.65	16321.0	Australia
180	C489449	21895	POTTING SHED SOW 'N' GROW SET	-4	2009-12-01 10:33:00	4.25	16321.0	Australia
181	C489449	21896	POTTING SHED TWINE	-6	2009-12-01 10:33:00	2.10	16321.0	Australia
182	C489449	22083	PAPER CHAIN KIT RETRO SPOT	-12	2009-12-01 10:33:00	2.95	16321.0	Australia

*Xác định và loại bỏ giao dịch bị hủy

- Trong quá trình khám phá dữ liệu, nhóm phát hiện rằng một số mã hóa đơn trong cột Invoice bắt đầu bằng ký tự “C”.

- Sau khi tìm hiểu tài liệu mô tả dataset, nhóm nhận ra rằng các hóa đơn này đại diện cho các giao dịch bị hủy (cancel transactions).

- Nếu giữ lại những dòng dữ liệu này, các phân tích về doanh thu sẽ bị sai lệch vì:

+ Những giao dịch này không tạo ra doanh thu thực tế

+ Chúng có thể khiến việc tính toán doanh thu và tần suất mua hàng trở nên không chính xác

- Vì vậy, nhóm quyết định loại bỏ toàn bộ các giao dịch bị hủy để đảm bảo dataset chỉ bao gồm các giao dịch mua hàng thực sự.

```
# Kiểm tra các giá trị không hợp lệ
invalid_qty = (df['Quantity'] <= 0).sum()
invalid_price = (df['Price'] <= 0).sum()

print("Quantity không hợp lệ:", invalid_qty)
print("Price không hợp lệ:", invalid_price)
```

```
Quantity không hợp lệ: 9816
Price không hợp lệ: 31
```

```
# Loại bỏ các dòng có Quantity <= 0 hoặc Price <= 0
df = df[(df['Quantity'] > 0)]
df = df[(df['Price'] > 0)]

print("Sau xử lý:")
print("Quantity <= 0:", (df['Quantity'] <= 0).sum())
print("Price <= 0:", (df['Price'] <= 0).sum())
```

```
Sau xử lý:
Quantity <= 0: 0
Price <= 0: 0
```

* Xử lý dữ liệu không hợp lệ (Invalid Values)

- Trong bước tiếp theo, nhóm kiểm tra các giá trị bất thường ở hai biến quan trọng:

+ Quantity (số lượng sản phẩm)

+ Price (giá bán)

- Kết quả kiểm tra cho thấy tồn tại một số giá trị nhỏ hơn hoặc bằng 0.

- Ban đầu, nhóm đã cân nhắc khả năng rằng các giá trị âm có thể phản ánh các trường hợp trả hàng (returns). Tuy nhiên, vì dataset đã loại bỏ các giao dịch bị hủy trước đó và mục tiêu của bài toán là phân tích hành vi mua và doanh thu, việc giữ lại các giá trị này có thể làm nhiễu kết quả phân tích.

- Do đó, nhóm quyết định chỉ giữ lại các giao dịch có Quantity > 0 và Price > 0. Điều này giúp đảm bảo rằng dataset chỉ bao gồm các giao dịch bán hàng hợp lệ và có ý nghĩa kinh tế.

```
# Chuyển InvoiceDate sang dạng datetime
df['InvoiceDate'] = pd.to_datetime(df['InvoiceDate'])

print(df.dtypes)
```

```
Invoice          object
StockCode        object
Description       object
Quantity         int64
InvoiceDate      datetime64[ns]
Price            float64
Customer ID      float64
Country          object
dtype: object
```

```
# Tạo biến doanh thu
df['Revenue'] = df['Quantity'] * df['Price']

df[['Quantity', 'Price', 'Revenue']].head()
```

	Quantity	Price	Revenue
0	12	6.95	83.4
1	12	6.75	81.0
2	12	6.75	81.0
3	48	2.10	100.8
4	24	1.25	30.0

*Tạo biến Revenue

- Dataset ban đầu không chứa biến thể hiện doanh thu của từng giao dịch.
- Để thuận tiện cho việc phân tích, nhóm tạo thêm biến Revenue theo công thức:
- $Revenue = Quantity \times Price$
- Việc tạo biến này giúp:
 - + Đơn giản hóa các phép tính trong các bước phân tích sau
 - + Đảm bảo rằng toàn bộ nhóm sử dụng cùng một định nghĩa về doanh thu
 - + Giảm nguy cơ sai lệch khi tính toán ở các bước sau

```
# Tách Year và Month từ InvoiceDate
df['Year'] = df['InvoiceDate'].dt.year
df['Month'] = df['InvoiceDate'].dt.month

df[['InvoiceDate', 'Year', 'Month']].head()
```

	InvoiceDate	Year	Month
0	2009-12-01 07:45:00	2009	12
1	2009-12-01 07:45:00	2009	12
2	2009-12-01 07:45:00	2009	12
3	2009-12-01 07:45:00	2009	12
4	2009-12-01 07:45:00	2009	12

* Chuẩn hóa kiểu dữ liệu (Data Type Standardization)

- Một vấn đề khác được phát hiện là cột InvoiceDate ban đầu được lưu dưới dạng chuỗi (string). Điều này gây khó khăn khi thực hiện các phân tích theo thời gian như:

- + Phân tích theo tháng
- + Phân tích theo năm
- + Phân tích xu hướng doanh thu theo thời gian

-> Vì vậy, nhóm đã chuyển cột này sang kiểu dữ liệu datetime bằng phương thức `pd.to_datetime()`.

- Sau khi chuẩn hóa kiểu dữ liệu, nhóm có thể dễ dàng trích xuất các thông tin thời gian như Year và Month, phục vụ cho các bước phân tích xu hướng sau này.

```
# Kiểm tra các biến định danh trong dataset
print("Số lượng Invoice:", df['Invoice'].nunique())
print("Số lượng Customer ID:", df['Customer ID'].nunique())
print("Số lượng StockCode:", df['StockCode'].nunique())
```

```
Số lượng Invoice: 19213
Số lượng Customer ID: 4312
Số lượng StockCode: 4017
```

* Xác định mối quan hệ dữ liệu (Data Relationship)

- Ngoài việc làm sạch dữ liệu, nhóm cũng xác định các biến đóng vai trò định danh trong dataset nhằm phục vụ cho việc phân tích và liên kết dữ liệu.

- Cụ thể:
 - + Invoice được sử dụng để định danh từng hóa đơn giao dịch
 - + Customer ID được sử dụng để xác định từng khách hàng
 - + StockCode đại diện cho từng sản phẩm

- Việc kiểm tra các biến định danh giúp nhóm hiểu rõ mối quan hệ giữa khách hàng, sản phẩm và giao dịch trong dataset. Đồng thời, bước này cũng hỗ trợ đảm bảo dữ liệu có thể được tích hợp hoặc mở rộng dễ dàng trong các phân tích tiếp theo.

```
# Xử lý Outliers bằng phương pháp IQR

print("Thông kê trước khi xử lý:")
print(df['Quantity'].describe())

Q1 = df['Quantity'].quantile(0.25)
Q3 = df['Quantity'].quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

df = df[(df['Quantity'] >= lower_bound) & (df['Quantity'] <= upper_bound)]

print("Thông kê sau khi xử lý:")
print(df['Quantity'].describe())
```

```
...   Thông kê trước khi xử lý:
count    400916.000000
mean         13.767418
std         97.638385
min           1.000000
25%           2.000000
50%           5.000000
75%          12.000000
max        19152.000000
Name: Quantity, dtype: float64
Thông kê sau khi xử lý:
count    374622.000000
mean         6.821273
std         6.525594
min           1.000000
25%           2.000000
50%           4.000000
75%          12.000000
max         27.000000
Name: Quantity, dtype: float64
```

*Xử lý Outliers

- Sau khi hoàn thành các bước cleaning cơ bản, nhóm tiến hành kiểm tra phân phối dữ liệu của biến Quantity và nhận thấy tồn tại một số giá trị cực lớn so với phần còn lại của dataset.

Các giá trị này có thể là:

+ Các đơn hàng số lượng rất lớn

+ Hoặc các giá trị nhập sai

- Nếu giữ lại những giá trị cực đoan này, các chỉ số thống kê như mean có thể bị kéo lệch, khiến dữ liệu không còn đại diện cho hành vi mua hàng phổ biến của khách hàng.

Sau khi cân nhắc, nhóm quyết định xử lý outliers bằng phương pháp IQR (Interquartile Range).

- Phương pháp này xác định ngưỡng:

+ Lower Bound = $Q1 - 1.5 \times IQR$

+ Upper Bound = $Q3 + 1.5 \times IQR$

- Các giá trị nằm ngoài khoảng này được xem là outliers và được loại bỏ khỏi dataset.

- Nhóm lựa chọn IQR thay vì Z-score vì:

+ Dữ liệu không có dấu hiệu tuân theo phân phối chuẩn

+ IQR ổn định hơn và ít bị ảnh hưởng bởi các giá trị cực đoan

Sau khi áp dụng phương pháp này, dataset trở nên ổn định và đại diện hơn cho hành vi mua hàng điển hình.

* Một vấn đề phát sinh trong quá trình xử lý dữ liệu

- Trong quá trình làm việc với dataset, nhóm gặp một vấn đề thú vị liên quan đến việc chạy lại notebook nhiều lần.

- Ở lần chạy đầu tiên, kết quả của các bước kiểm tra dữ liệu (ví dụ số lượng giá trị không hợp lệ) hoàn toàn hợp lý. Tuy nhiên, khi chạy lại toàn bộ notebook, một số kết quả thống kê lại thay đổi so với ban đầu.

- Sau khi kiểm tra lại pipeline xử lý dữ liệu, nhóm nhận ra nguyên nhân là do dataset đã bị thay đổi sau khi các bước cleaning được thực hiện. Khi chạy lại các bước kiểm tra trên dataset đã được xử lý trước đó, các giá trị không hợp lệ đã bị loại bỏ nên kết quả kiểm tra trở thành 0.

- Để khắc phục vấn đề này, nhóm đã điều chỉnh lại notebook theo hướng:

+ Luôn đọc lại dữ liệu gốc (raw dataset) ngay từ đầu notebook

+ Đảm bảo rằng mọi bước cleaning đều được thực hiện theo đúng thứ tự

+ Không sử dụng lại dataset đã bị biến đổi từ lần chạy trước

Cách tiếp cận này giúp notebook trở nên reproducible, nghĩa là mỗi lần chạy lại toàn bộ pipeline đều cho ra kết quả nhất quán.

2. KIỂM TRA VÀ HỢP NHẤT (DATA INTEGRATION)

- Vì dataset được cung cấp dưới dạng một bảng dữ liệu hoàn chỉnh nên nhóm không cần thực hiện việc hợp nhất nhiều file dữ liệu khác nhau bằng `pd.concat()` hoặc `pd.merge()`.

- Tuy nhiên, nhóm vẫn thực hiện kiểm tra:

+ Tính nhất quán của cấu trúc dữ liệu,

+ Các biến định danh

+ Mối quan hệ giữa các thành phần dữ liệu

nhằm đảm bảo dataset sẵn sàng cho việc tích hợp hoặc mở rộng trong tương lai.

Toàn bộ quá trình xử lý dữ liệu được thực hiện bằng Python và Pandas thay vì thao tác thủ công, giúp:

+ Giảm nguy cơ sai sót,

+ Đảm bảo tính nhất quán

+ Tăng khả năng tái lập của quy trình phân tích dữ liệu.

```
# Lưu dataset đã làm sạch
output_path = '/content/drive/MyDrive/Colab Notebooks/data4/online_retail_II_clean.xlsx'
df.to_excel(output_path, index=False)

print("Đã lưu file tại:", output_path)
```

Đã lưu file tại: /content/drive/MyDrive/Colab Notebooks/data4/online_retail_II_clean.xlsx

* Kết quả sau khi làm sạch dữ liệu

- Sau khi hoàn thành toàn bộ quy trình cleaning, dataset đã thay đổi đáng kể so với dữ liệu ban đầu:

+ Các dòng thiếu Customer ID đã được loại bỏ

+ Các giao dịch bị hủy không còn xuất hiện

+ Các giá trị không hợp lệ của Quantity và Price đã được xử lý

+ Kiểu dữ liệu thời gian đã được chuẩn hóa

+ Biến Revenue đã được bổ sung

- + Các outliers đã được loại bỏ
- Nhờ quá trình này, dataset không chỉ trở nên sạch hơn về mặt kỹ thuật, mà còn phù hợp hơn với mục tiêu phân tích hành vi khách hàng và doanh thu.

* Lưu dữ liệu đã làm sạch

- Sau khi hoàn tất toàn bộ quá trình xử lý, dataset đã được lưu lại thành một file mới: `clean_data.xlsx`
- File này đóng vai trò là refined dataset, được sử dụng làm đầu vào cho các bước tiếp theo của dự án như:
 - + Exploratory Data Analysis (EDA)
 - + Visualization
 - + Customer behavior analysis
 - + Insight extraction
- Việc tách riêng dữ liệu gốc (raw data) và dữ liệu đã làm sạch (clean data) giúp đảm bảo tính minh bạch và khả năng tái lập của toàn bộ quá trình phân tích.

3. PHÂN TÍCH KHÁM PHÁ (EDA - EXPLORATORY DATA ANALYSIS)

```
# Kiểm tra dataset cuối
print("Kích thước cuối:", df.shape)
df.info()
df.describe()
```

```
Kích thước cuối: (374622, 11)
<class 'pandas.core.frame.DataFrame'>
Index: 374622 entries, 0 to 525460
Data columns (total 11 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   Invoice          374622 non-null object
1   StockCode       374622 non-null object
2   Description     374622 non-null object
3   Quantity        374622 non-null int64
4   InvoiceDate     374622 non-null datetime64[ns]
5   Price          374622 non-null float64
6   Customer ID    374622 non-null float64
7   Country        374622 non-null object
8   Revenue        374622 non-null float64
9   Year           374622 non-null int32
10  Month          374622 non-null int32
dtypes: datetime64[ns](1), float64(3), int32(2), int64(1), object(4)
memory usage: 31.4+ MB
```

	Quantity	InvoiceDate	Price	Customer ID	Revenue	Year	Month
count	374622.000000	374622	374622.000000	374622.000000	374622.000000	374622.000000	374622.000000
mean	6.821273	2010-07-01 15:00:23.792142080	3.438639	15376.868192	14.785738	2009.924847	7.406845
min	1.000000	2009-12-01 07:45:00	0.001000	12346.000000	0.001000	2009.000000	1.000000
25%	2.000000	2010-03-26 13:57:00	1.250000	14014.000000	4.650000	2010.000000	4.000000
50%	4.000000	2010-07-09 15:48:00	1.950000	15353.000000	10.500000	2010.000000	8.000000
75%	12.000000	2010-10-15 12:11:00	3.750000	16822.000000	17.700000	2010.000000	11.000000
max	27.000000	2010-12-09 20:01:00	10953.500000	18287.000000	10953.500000	2010.000000	12.000000
std	6.525594	NaN	36.250903	1678.107168	39.986818	0.263639	3.474431

```
# Kiểm tra cấu trúc dữ liệu: số dòng, kiểu dữ liệu, missing values
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 374622 entries, 0 to 525460
Data columns (total 11 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Invoice          374622 non-null object
1   StockCode       374622 non-null object
2   Description     374622 non-null object
3   Quantity        374622 non-null int64
4   InvoiceDate     374622 non-null datetime64[ns]
5   Price           374622 non-null float64
6   Customer ID    374622 non-null float64
7   Country         374622 non-null object
8   Revenue         374622 non-null float64
9   Year            374622 non-null int32
10  Month           374622 non-null int32
dtypes: datetime64[ns](1), float64(3), int32(2), int64(1), object(4)
memory usage: 31.4+ MB
```

📌 Nhận xét:

Dataset bao gồm các biến định lượng (Quantity, Price) và định tính (Country, Description,...). Sau quá trình làm sạch, dữ liệu đã loại bỏ các lỗi định dạng và trở nên nhất quán hơn, giúp đảm bảo độ tin cậy cho các phân tích tiếp theo.

```
# Thống kê mô tả các biến số: mean, min, max, độ lệch chuẩn
df.describe()
```

	Quantity	InvoiceDate	Price	Customer ID	Revenue	Year	Month
count	374622.000000	374622	374622.000000	374622.000000	374622.000000	374622.000000	374622.000000
mean	6.821273	2010-07-01 15:00:23.792142080	3.438639	15376.868192	14.785738	2009.924847	7.406845
min	1.000000	2009-12-01 07:45:00	0.001000	12346.000000	0.001000	2009.000000	1.000000
25%	2.000000	2010-03-26 13:57:00	1.250000	14014.000000	4.650000	2010.000000	4.000000
50%	4.000000	2010-07-09 15:48:00	1.950000	15353.000000	10.500000	2010.000000	8.000000
75%	12.000000	2010-10-15 12:11:00	3.750000	16822.000000	17.700000	2010.000000	11.000000
max	27.000000	2010-12-09 20:01:00	10953.500000	18287.000000	10953.500000	2010.000000	12.000000
std	6.525594	NaN	36.250903	1678.107168	39.986818	0.263639	3.474431

📌 Nhận xét:

Quantity và Price có khoảng giá trị rộng, thể hiện mức độ phân tán cao trong dữ liệu. Giá trị lớn ở phần max cho thấy vẫn tồn tại các giao dịch có quy mô bất thường (outliers), tuy nhiên mức độ đã giảm đáng kể sau quá trình làm sạch.

```
# Đếm số lượng giao dịch theo từng quốc gia
df['Country'].value_counts().head(10)
```

Country	count
United Kingdom	342503
EIRE	7607
Germany	7078
France	4990
Netherlands	1439
Spain	1143
Switzerland	986
Belgium	980
Portugal	906
Channel Islands	756

dtype: int64

📌 Nhận xét:

United Kingdom chiếm tỷ trọng vượt trội về số lượng giao dịch so với các quốc gia khác, cho thấy đây là thị trường cốt lõi của doanh nghiệp.

Các quốc gia như France, Germany và Netherlands cũng có giao dịch đáng kể nhưng thấp hơn nhiều so với United Kingdom, cho thấy doanh nghiệp đã có sự hiện diện quốc tế nhưng chưa phân bổ đồng đều giữa các thị trường.

Điều này phản ánh mức độ phụ thuộc cao vào thị trường United Kingdom, tiềm ẩn rủi ro nếu thị trường này biến động.

```
# Đếm số lần xuất hiện của từng sản phẩm
df['Description'].value_counts().head(10)
```

Description	count
WHITE HANGING HEART T-LIGHT HOLDER	2455
REGENCY CAKESTAND 3 TIER	1622
STRAWBERRY CERAMIC TRINKET BOX	1202
HOME BUILDING BLOCK WORD	1189
REX CASH+CARRY JUMBO SHOPPER	1098
ASSORTED COLOUR BIRD ORNAMENT	1073
60 TEATIME FAIRY CAKE CASES	1013
WOODEN FRAME ANTIQUE WHITE	993
HEART OF WICKER LARGE	984
PACK OF 72 RETRO SPOT CAKE CASES	969

dtype: int64

📌 Nhận xét:

Một số sản phẩm có tần suất xuất hiện cao hơn đáng kể so với phần còn lại. Điều này cho thấy nhu cầu tập trung vào một số sản phẩm chủ lực, trong khi các sản phẩm khác có mức tiêu thụ thấp hơn. Doanh nghiệp có thể tận dụng nhóm sản phẩm này để tối ưu doanh thu và chiến lược kinh doanh.

```
# Tính ma trận tương quan giữa các biến số
df.corr(numeric_only=True)
```

	Quantity	Price	Customer ID	Revenue	Year	Month
Quantity	1.000000	-0.036651	-0.125879	0.171240	0.012415	-0.015112
Price	-0.036651	1.000000	-0.006644	0.912373	0.000763	-0.004984
Customer ID	-0.125879	-0.006644	1.000000	-0.049246	-0.019780	0.037496
Revenue	0.171240	0.912373	-0.049246	1.000000	-0.002740	-0.007438
Year	0.012415	0.000763	-0.019780	-0.002740	1.000000	-0.376848
Month	-0.015112	-0.004984	0.037496	-0.007438	-0.376848	1.000000

📌 Nhận xét:

Ma trận tương quan cho thấy mối quan hệ giữa Quantity và Price là yếu. Điều này cho thấy số lượng mua không bị ảnh hưởng mạnh bởi giá, có thể do đặc thù sản phẩm hoặc hành vi mua hàng mang tính nhu cầu hơn là nhạy cảm về giá.

```
# Tính tổng số lượng mua theo từng quốc gia
df.groupby('Country')['Quantity'].sum().sort_values(ascending=False)
```

Country	Quantity
United Kingdom	2235429
Germany	73085
EIRE	72974
France	49933
Netherlands	14013
Switzerland	11153
Spain	10923
Belgium	9365
Portugal	8613
Channel Islands	7037

Sweden	6537
Italy	5600
Australia	5547
Austria	5271
Greece	4689
Norway	4274
Denmark	3928
Finland	3323
Cyprus	3278
United Arab Emirates	3089
Unspecified	2776
USA	1990
Lithuania	1880
Poland	1848
...	...
Poland	1848
Malta	1261
Singapore	1221
Japan	1079
Israel	894
Canada	894
Iceland	762
RSA	591
Thailand	524
Korea	520
Bahrain	447
West Indies	359
Brazil	189
Nigeria	103

📌 Nhận xét:

United Kingdom có tổng số lượng mua cao nhất, vượt xa các quốc gia khác. France và Germany đứng sau nhưng với khoảng cách đáng kể, cho thấy sự chênh lệch lớn giữa các thị trường và mức độ tập trung cao vào United Kingdom.

```
# Tính tổng số lượng bán theo từng sản phẩm
df.groupby('Description')['Quantity'].sum().sort_values(ascending=False).head(10)
```

Quantity	
Description	
WHITE HANGING HEART T-LIGHT HOLDER	17305
PACK OF 72 RETRO SPOT CAKE CASES	16913
60 TEATIME FAIRY CAKE CASES	15035
ASSORTED COLOUR BIRD ORNAMENT	13175
PACK OF 60 PINK PAISLEY CAKE CASES	12222
STRAWBERRY CERAMIC TRINKET BOX	12166
HANGING HEART ZINC T-LIGHT HOLDER	8677
PACK OF 72 SKULL CAKE CASES	8579
LUNCH BAG RED SPOTTY	8545
ZINC METAL HEART DECORATION	8131

dtype: int64

📌 Nhận xét:

Các sản phẩm đứng đầu về số lượng bán có sự vượt trội rõ rệt so với các sản phẩm còn lại. Điều này cho thấy doanh thu có xu hướng tập trung vào một số ít sản phẩm chủ lực, tạo cơ hội để doanh nghiệp tập trung phát triển và tối ưu các sản phẩm này.

```
# Tạo biến doanh thu = Quantity * Price
df['Revenue'] = df['Quantity'] * df['Price']

# Tính tổng doanh thu theo quốc gia
df.groupby('Country')['Revenue'].sum().sort_values(ascending=False)
```

Revenue	
Country	
United Kingdom	4777773.763
EIRE	194323.020
Germany	160494.861
France	104650.590
Netherlands	35447.890
Switzerland	26470.070
Spain	25084.550
Belgium	22453.380
Norway	20745.480
Portugal	18635.180
Channel Islands	17439.700
Sweden	15505.950
Australia	14046.620
Italy	13724.690
Greece	12351.290
Austria	11273.950
Denmark	9662.090
Cyprus	9307.860
Finland	6399.780
United Arab Emirates	6243.890
Unspecified	5594.380
Malta	5109.260
Lithuania	4253.080
USA	4101.510
Poland	3214.880
Singapore	2729.730
Israel	2682.500
Japan	2150.420
Iceland	1262.420
Canada	1216.660
Thailand	1113.700
Korea	955.910
RSA	931.430
Bahrain	774.770
West Indies	528.850
Brazil	268.270
Nigeria	140.390


dtype: float64

📌 Nhận xét:

United Kingdom dẫn đầu về doanh thu với khoảng cách lớn so với các quốc gia khác. Các quốc gia như France và Germany đóng góp một phần doanh thu nhưng tỷ trọng còn hạn chế, cho thấy doanh thu chưa được đa dạng hóa giữa các thị trường. Điều này gợi ý doanh nghiệp có thể mở rộng và khai thác tốt hơn các thị trường quốc tế để giảm phụ thuộc vào United Kingdom.

```
# Vẽ histogram để quan sát phân phối của Quantity
import matplotlib.pyplot as plt

plt.hist(df['Quantity'], bins=50)
plt.title('Distribution of Quantity')
plt.xlabel('Quantity')
plt.ylabel('Frequency')
plt.show()
```

📌 Nhận xét:

Phân phối của Quantity có dạng lệch phải, với phần lớn giao dịch tập trung ở mức thấp và một số ít giao dịch có giá trị rất cao. Điều này cho thấy hành vi mua hàng phổ biến là mua với số lượng nhỏ, trong khi các đơn hàng lớn mang tính ngoại lệ.

```
# Vẽ boxplot để phát hiện outliers
plt.boxplot(df['Quantity'])
plt.title('Boxplot of Quantity')
plt.show()
```



📌 Nhận xét:

Boxplot cho thấy vẫn tồn tại một số outliers sau khi làm sạch, tuy nhiên mức độ không còn quá cực đoan. Điều này cho thấy quá trình cleaning đã cải thiện chất lượng dữ liệu nhưng vẫn giữ lại các giá trị quan trọng có thể phản ánh hành vi mua hàng thực tế.

Dữ liệu ban đầu chứa nhiều vấn đề như giá trị thiếu, dữ liệu bất thường và outliers. Sau quá trình làm sạch, dữ liệu trở nên nhất quán và đáng tin cậy hơn. Kết quả phân tích cho thấy doanh nghiệp phụ thuộc mạnh vào thị trường United Kingdom, trong khi các thị trường quốc tế khác vẫn chưa được khai thác đầy đủ. Ngoài ra, doanh thu và số lượng bán có xu hướng tập trung vào một số sản phẩm chủ lực, và hành vi mua hàng chủ yếu là các đơn hàng nhỏ với một số ít giao dịch có giá trị lớn.

4. ĐÁNH GIÁ BẰNG BIỂU ĐỒ (VISUAL ANALYSIS)

*Biểu đồ doanh thu theo thời gian


```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
# Kiểm tra thử 5 dòng đầu
df.head()
```

	Invoice	StockCode	Description	Quantity	InvoiceDate	Price	Customer ID	Country	Revenue	Year	Month
0	489434	85048	15CM CHRISTMAS GLASS BALL 20 LIGHTS	12	2009-12-01 07:45:00	6.95	13085.0	United Kingdom	83.4	2009	12
1	489434	79323P	PINK CHERRY LIGHTS	12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom	81.0	2009	12
2	489434	79323W	WHITE CHERRY LIGHTS	12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom	81.0	2009	12
4	489434	21232	STRAWBERRY CERAMIC TRINKET BOX	24	2009-12-01 07:45:00	1.25	13085.0	United Kingdom	30.0	2009	12
5	489434	22064	PINK DOUGHNUT TRINKET POT	24	2009-12-01 07:45:00	1.65	13085.0	United Kingdom	39.6	2009	12


```
# Chuyển đổi 'InvoiceDate' thành định dạng datetime nếu chưa được chuyển đổi
df['InvoiceDate'] = pd.to_datetime(df['InvoiceDate'])

# Tạo cột 'YearMonth' để nhóm theo tháng
df['YearMonth'] = df['InvoiceDate'].dt.to_period('M')

# Tính tổng doanh thu theo tháng
monthly_revenue = df.groupby('YearMonth')['Revenue'].sum().reset_index()

# Chuyển đổi 'YearMonth' về datetime để vẽ biểu đồ dễ dàng hơn
monthly_revenue['YearMonth'] = monthly_revenue['YearMonth'].dt.to_timestamp()

plt.figure(figsize=(12, 6))
sns.lineplot(x='YearMonth', y='Revenue', data=monthly_revenue)
plt.title('Tổng Doanh thu theo Tháng (Line Chart)')
plt.xlabel('Thời gian')
plt.ylabel('Tổng Doanh thu')
plt.grid(True)
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```




Ⓢ **Nhận xét:** Từ biểu đồ trên, chúng ta có thể thấy một số xu hướng về doanh thu:

Xu hướng tăng trưởng: Có vẻ như doanh thu có xu hướng tăng dần theo thời gian, đặc biệt là vào cuối năm 2010 và 2011. **Tính thời vụ:** Doanh thu thường đạt đỉnh vào cuối mỗi năm (tháng 11 và 12), cho thấy tính thời vụ mạnh mẽ, có thể liên quan đến các dịp lễ hội hoặc mua sắm cuối năm. **Biến động:** Có những biến động đáng kể giữa các tháng, nhưng xu hướng chung vẫn là tăng trưởng.

*Top sản phẩm / quốc gia (Bar Chart)

```
# Top 10 sản phẩm theo doanh thu
top_products = df.groupby('Description')['Revenue'].sum().nlargest(10).reset_index()

plt.figure(figsize=(12, 7))
sns.barplot(x='Revenue', y='Description', data=top_products, palette='viridis')
plt.title('Top 10 Sản phẩm có Doanh thu cao nhất')
plt.xlabel('Tổng Doanh thu')
plt.ylabel('Tên sản phẩm')
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()
```




Ⓢ Nhận xét về Top 10 Sản phẩm có Doanh thu cao nhất:

Biểu đồ này hiển thị 10 sản phẩm đóng góp nhiều nhất vào tổng doanh thu. Từ đó, chúng ta có thể:

- Xác định sản phẩm chủ lực: Các sản phẩm như 'Manual' và 'REGENCY CAKESTAND 3 TIER' có doanh thu vượt trội, cho thấy chúng là những mặt hàng bán chạy nhất hoặc có giá trị cao. Chiến lược kinh doanh: Doanh nghiệp có thể tập trung vào việc duy trì chất lượng và đẩy mạnh tiếp thị cho các sản phẩm này, đồng thời nghiên cứu lý do thành công để áp dụng cho các sản phẩm khác.

*Top 10 quốc gia theo doanh thu



Ⓢ Nhận xét về Top 10 Quốc gia có Doanh thu cao nhất:

Biểu đồ này cho thấy các quốc gia đóng góp nhiều nhất vào doanh thu:



- Thị trường trọng điểm: 'United Kingdom' chiếm phần lớn doanh thu, khẳng định đây là thị trường chính của doanh nghiệp. Các quốc gia khác như EIRE, Germany, France cũng đóng góp đáng kể. Cơ hội mở rộng: Doanh nghiệp có thể xem xét các chiến lược đầu tư hoặc mở rộng thị phần tại các quốc gia có tiềm năng nhưng doanh thu chưa cao.

```
# Phân bố số lượng đơn hàng (Quantity)
plt.figure(figsize=(15, 6))

plt.subplot(1, 2, 1) # Histogram
sns.histplot(df['Quantity'], bins=50, kde=True)
plt.title('Phân bố số lượng đơn hàng (Histogram)')
plt.xlabel('Số lượng')
plt.ylabel('Tần suất')

plt.subplot(1, 2, 2) # Boxplot
sns.boxplot(y=df['Quantity'])
plt.title('Phân bố số lượng đơn hàng (Boxplot)')
plt.ylabel('Số lượng')

plt.tight_layout()
plt.show()
```



📌 Nhận xét về Phân bố số lượng đơn hàng (Quantity):

Histogram: Biểu đồ histogram cho thấy phần lớn các đơn hàng có số lượng sản phẩm rất nhỏ, tập trung ở phía bên trái. Điều này ngụ ý rằng khách hàng thường mua số lượng ít sản phẩm trong một lần.



Boxplot: Biểu đồ boxplot xác nhận rằng phần lớn dữ liệu Quantity nằm trong một phạm vi hẹp. Đồng thời, sự hiện diện của rất nhiều điểm ngoại lai (outliers) phía trên cho thấy có những đơn hàng với số lượng sản phẩm cực lớn, có thể là đơn hàng bán buôn hoặc đặt hàng đặc biệt.

```
# Phân bố giá trị đơn hàng (Revenue)
plt.figure(figsize=(15, 6))

plt.subplot(1, 2, 1) # Histogram
sns.histplot(df['Revenue'], bins=50, kde=True)
plt.title('Phân bố giá trị đơn hàng (Histogram)')
plt.xlabel('Doanh thu')
plt.ylabel('Tần suất')

plt.subplot(1, 2, 2) # Boxplot
sns.boxplot(y=df['Revenue'])
plt.title('Phân bố giá trị đơn hàng (Boxplot)')
plt.ylabel('Doanh thu')

plt.tight_layout()
plt.show()
```



📌 Nhận xét về Phân bố giá trị đơn hàng (Revenue):

Histogram: Tương tự như Quantity, biểu đồ histogram của Revenue cũng cho thấy phần lớn doanh thu đến từ các đơn hàng có giá trị nhỏ, tập trung ở mức thấp. Điều này phù hợp với việc khách hàng mua số lượng ít sản phẩm.

Boxplot: Biểu đồ boxplot minh họa rõ ràng rằng phần lớn giá trị doanh thu nằm ở mức thấp, với một số lượng lớn các điểm ngoại lai có giá trị rất cao. Điều này chỉ ra rằng, mặc dù đa số đơn hàng có giá trị nhỏ, nhưng có một số ít đơn hàng có giá trị rất lớn, đóng góp đáng kể vào tổng doanh thu.

```
# Import các thư viện cần thiết
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from datetime import datetime
```

```
# Hiển thị 5 dòng đầu tiên của dataset
df.head()
```

	Invoice	StockCode	Description	Quantity	InvoiceDate	Price	Customer ID	Country	Revenue	Year	Month	YearMonth
0	489434	85048	15CM CHRISTMAS GLASS BALL 20 LIGHTS	12	2009-12-01 07:45:00	6.95	13085.0	United Kingdom	83.4	2009	12	2009-12
1	489434	79323P	PINK CHERRY LIGHTS	12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom	81.0	2009	12	2009-12
2	489434	79323W	WHITE CHERRY LIGHTS	12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom	81.0	2009	12	2009-12
4	489434	21232	STRAWBERRY CERAMIC TRINKET BOX	24	2009-12-01 07:45:00	1.25	13085.0	United Kingdom	30.0	2009	12	2009-12
5	489434	22064	PINK DOUGHNUT TRINKET POT	24	2009-12-01 07:45:00	1.65	13085.0	United Kingdom	39.6	2009	12	2009-12

```
# Hiển thị tên các cột trong dataset
print(df.columns)
```

```
Index(['Invoice', 'StockCode', 'Description', 'Quantity', 'InvoiceDate',
       'Price', 'Customer ID', 'Country', 'Revenue', 'Year', 'Month',
       'YearMonth'],
      dtype='object')
```

```
# Kiểm tra thông tin dataset sau khi clean
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 374622 entries, 0 to 525460
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   Invoice      374622 non-null  object
1   StockCode   374622 non-null  object
2   Description  374622 non-null  object
3   Quantity    374622 non-null  int64
4   InvoiceDate  374622 non-null  datetime64[ns]
5   Price       374622 non-null  float64
6   Customer ID  374622 non-null  float64
7   Country     374622 non-null  object
8   Revenue     374622 non-null  float64
9   Year        374622 non-null  int32
10  Month       374622 non-null  int32
11  YearMonth   374622 non-null  period[M]
dtypes: datetime64[ns](1), float64(3), int32(2), int64(1), object(4), period[M](1)
memory usage: 34.3+ MB
```

```
# Chuyển cột InvoiceDate sang kiểu datetime
df['InvoiceDate'] = pd.to_datetime(df['InvoiceDate'])
```

```
# Kiểm tra thông tin dataset sau khi clean
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 374622 entries, 0 to 525460
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   Invoice      374622 non-null  object
1   StockCode   374622 non-null  object
2   Description  374622 non-null  object
3   Quantity    374622 non-null  int64
4   InvoiceDate  374622 non-null  datetime64[ns]
5   Price       374622 non-null  float64
6   Customer ID  374622 non-null  float64
7   Country     374622 non-null  object
8   Revenue     374622 non-null  float64
9   Year        374622 non-null  int32
10  Month       374622 non-null  int32
11  YearMonth   374622 non-null  period[M]
dtypes: datetime64[ns](1), float64(3), int32(2), int64(1), object(4), period[M](1)
memory usage: 34.3+ MB
```

Tạo snapshot date để tính Recency

df['TotalPrice'] = df['Quantity'] * df['Price']

snapshot_date = df['InvoiceDate'].max() + pd.Timedelta(days=1)

print(snapshot_date)

2010-12-10 20:01:00

Tính Recency, Frequency và Monetary cho từng khách hàng

rfm = df.groupby('Customer ID').agg({

'InvoiceDate': lambda x: (snapshot_date - x.max()).days,

'Invoice': 'nunique',

'TotalPrice': 'sum'

})

Đổi tên cột

rfm.columns = ['Recency', 'Frequency', 'Monetary']

Hiển thị kết quả

rfm.head()

Recency Frequency Monetary

Customer ID

12346.0	165	11	372.86
12347.0	3	2	1262.42
12348.0	74	1	222.16
12349.0	43	3	2630.34
12351.0	11	1	300.93

Các bước tiếp theo:

Tạo mã bảng rfm

New interactive sheet

Chia Recency thành 4 nhóm điểm

rfm['R_score'] = pd.qcut(rfm['Recency'], 4, labels=[4,3,2,1])

Chia Frequency thành 4 nhóm điểm

rfm['F_score'] = pd.qcut(rfm['Frequency'].rank(method='first'), 4, labels=[1,2,3,4])

Chia Monetary thành 4 nhóm điểm

rfm['M_score'] = pd.qcut(rfm['Monetary'], 4, labels=[1,2,3,4])

Kết hợp điểm RFM thành một mã phân loại khách hàng

rfm['RFM_Score'] = (

rfm['R_score'].astype(str) +

rfm['F_score'].astype(str) +

rfm['M_score'].astype(str)

)

print(rfm.head())

Customer ID	Recency	Frequency	Monetary	R_score	F_score	M_score	RFM_Score
12346.0	165	11	372.86	1	4	2	142
12347.0	3	2	1262.42	4	2	3	423
12348.0	74	1	222.16	2	1	1	211
12349.0	43	3	2630.34	3	3	4	334
12351.0	11	1	300.93	4	1	2	412

Hàm phân nhóm khách hàng

def customer_segment(row):

if row['RFM_Score'] == '444':

return 'Best Customers'

elif row['R_score'] == 4:

return 'Recent Customers'

elif row['F_score'] == 4:

return 'Loyal Customers'

elif row['M_score'] == 4:

return 'Big Spenders'

else:

return 'Others'

rfm['Segment'] = rfm.apply(customer_segment, axis=1)

print(rfm.head())

...

Customer ID	Recency	Frequency	Monetary	R_score	F_score	M_score	RFM_Score	\
12346.0	165	11	372.86	1	4	2	142	
12347.0	3	2	1262.42	4	2	3	423	
12348.0	74	1	222.16	2	1	1	211	
12349.0	43	3	2630.34	3	3	4	334	
12351.0	11	1	300.93	4	1	2	412	

Segment

Customer ID	Segment
12346.0	Loyal Customers
12347.0	Recent Customers
12348.0	Others
12349.0	Big Spenders
12351.0	Recent Customers

*Phân khúc khách hàng

Vẽ biểu đồ phân nhóm khách hàng theo RFM

plt.figure(figsize=(10,6))

sns.countplot(x='Segment', data=rfm,


order=rfm['Segment'].value_counts().index)

plt.title('Phân nhóm khách hàng sử dụng RFM')

plt.xticks(rotation=20)

plt.show()

19



-> Nhận xét về Phân khúc khách hàng bằng mô hình RFM (Recency - Frequency - Monetary):

- Biểu đồ phân khúc khách hàng theo mô hình RFM cho thấy số lượng khách hàng tập trung chủ yếu ở nhóm Others, trong khi các nhóm khách hàng có giá trị cao như Best Customers, Loyal Customers và Big Spenders chiếm tỷ lệ thấp hơn.

- Từ kết quả này, có thể rút ra một số insight quan trọng như:

+ *Nhóm Others chiếm tỷ lệ lớn nhất:* Điều này cho thấy phần lớn khách hàng hiện tại chưa có mức độ tương tác hoặc giá trị mua hàng cao. Đây có thể là nhóm khách hàng mua ít, không thường xuyên hoặc có mức chi tiêu thấp.

+ *Best Customers và Loyal Customers có số lượng ít hơn nhưng quan trọng:* Mặc dù số lượng không nhiều, đây là nhóm khách hàng mang lại giá trị doanh thu lớn và có khả năng đóng góp đáng kể vào lợi nhuận doanh nghiệp. Nhóm này cần được ưu tiên chăm sóc và giữ chân.

+ *Big Spenders có số lượng thấp nhất:* Điều này cho thấy chỉ có một phần nhỏ khách hàng có mức chi tiêu rất cao. Doanh nghiệp có thể triển khai các chương trình cá nhân hóa hoặc ưu đãi VIP để tăng trải nghiệm cho nhóm khách hàng này.

+ *Recent Customers có tiềm năng phát triển:* Đây là nhóm khách hàng mới tương tác gần đây và có khả năng trở thành khách hàng trung thành nếu được chăm sóc phù hợp.

Ý nghĩa kinh doanh:

- Kết quả phân tích RFM giúp doanh nghiệp hiểu rõ giá trị của từng nhóm khách hàng để xây dựng chiến lược marketing phù hợp. Doanh nghiệp có thể:

- + Tập trung giữ chân nhóm khách hàng giá trị cao
- + Tăng cường loyalty program cho khách hàng trung thành
- + Thực hiện chiến dịch re-engagement cho nhóm Others
- + Cá nhân hóa ưu đãi nhằm tăng giá trị vòng đời khách hàng (Customer Lifetime Value)

***Top khách hàng có mức chi tiêu cao nhất**

```
# Tìm 10 khách hàng có mức chi tiêu cao nhất
top_customers = (
    rfm.sort_values(
        by='Monetary',
        ascending=False
    )
    .head(10)
)

print(top_customers)
```

```
...
Customer ID      Recency  Frequency  Monetary  R_score  F_score  M_score  RFM_Score  \
14911.0           1         205    129898.30      4      4      4         444
14156.0           14          83     57667.02      4      4      4         444
17850.0           8         155     50623.87      4      4      4         444
13089.0           4          89     35682.65      4      4      4         444
15311.0           1        116     29452.50      4      4      4         444
17841.0           1          90     27560.94      4      4      4         444
13081.0           7          18     23516.42      4      4      4         444
13093.0           9          45     22928.47      4      4      4         444
14298.0          11          34     22073.38      4      4      4         444
14646.0          10          59     19276.98      4      4      4         444

Customer ID      Segment
14911.0      Best Customers
14156.0      Best Customers
17850.0      Best Customers
13089.0      Best Customers
15311.0      Best Customers
17841.0      Best Customers
13081.0      Best Customers
13093.0      Best Customers
14298.0      Best Customers
14646.0      Best Customers
```

```
# Vẽ biểu đồ top 10 khách hàng có mức chi tiêu cao nhất
plt.figure(figsize=(12,6))


sns.barplot(
    x=top_customers.index.astype(str),
    y=top_customers['Monetary']
)

plt.title('Top 10 khách hàng có mức chi tiêu cao nhất')

plt.xlabel('Customer ID')
plt.ylabel('Tổng chi tiêu')

plt.xticks(rotation=45)

plt.show()
```



Sự xuất hiện của "Siêu khách hàng" (Outlier)

Khách hàng ID 14911: Đây là cá nhân nổi bật nhất với mức chi tiêu vượt xa phần còn lại, đạt hơn 120,000.

Mức chi tiêu của khách hàng này gấp hơn 2 lần người đứng thứ hai và gấp khoảng 6 lần người đứng thứ mười. Đây chính là đối tượng "Whale" (khách hàng cá voi) cực kỳ quan trọng đối với doanh thu của công ty.

Phân nhóm chi tiêu

- Dựa vào biểu đồ, có thể chia 10 khách hàng này thành 3 nhóm:
 - + Nhóm dẫn đầu (Top 1): ID 14911 (Chi tiêu > 120,000).

+ Nhóm tiềm năng cao (Top 2-3): ID 14156 và ID 17850. Hai khách hàng này có mức chi tiêu khá cao, dao động từ 50,000 đến 60,000.

+ Nhóm ổn định (Top 4-10): Các khách hàng còn lại có mức chi tiêu giảm dần khá đều, từ khoảng 40,000 xuống 20,000. Khoảng cách giữa các vị trí trong nhóm này không quá lớn, cho thấy sự cạnh tranh sát sao.

Ý nghĩa đối với doanh nghiệp (Nguyên lý Pareto)

- Biểu đồ này minh họa rất rõ nguyên lý 80/20: Một nhóm rất nhỏ khách hàng đang đóng góp một tỷ trọng doanh thu rất lớn.

- Chỉ cần giữ chân được 3 khách hàng đầu tiên (14911, 14156, 17850), doanh nghiệp đã bảo vệ được một phần lớn nguồn thu từ nhóm khách hàng VIP.

Gợi ý chiến lược hành động

- Chương trình khách hàng thân thiết (Loyalty Program):

+ Đối với ID 14911, cần có chế độ chăm sóc đặc biệt (quà tặng riêng, ưu tiên hỗ trợ, hoặc người quản lý tài khoản riêng) để đảm bảo họ không rời bỏ thương hiệu.

+ Với nhóm từ Top 4-10, có thể đưa ra các ưu đãi nâng cấp hạng thành viên để khuyến khích họ chi tiêu nhiều hơn nhằm tiến lên nhóm trên.

- Phân tích hành vi:

+ Bạn nên kiểm tra xem những khách hàng này thường mua gì. Ví dụ: Khách hàng 14911 có phải là người mua sỉ (B2B) không, hay là khách hàng cá nhân có sức mua lớn?

+ Nếu họ mua các sản phẩm ở biểu đồ trước (như Regency Cakestand hay các dịch vụ Manual), doanh nghiệp có thể giới thiệu các sản phẩm tương tự trực tiếp cho họ.

Kiểm tra tần suất:

- Cần xem thêm chỉ số về tần suất mua hàng (Frequency) để biết khách hàng 14911 chỉ đặt một lần hay mua hàng đều đặn mỗi tháng.

* Doanh thu theo tháng

```
top_customers = rfm.sort_values(  
    by='Monetary',  
    ascending=False  
) .head(10)
```

top_customers

	Recency	Frequency	Monetary	R_score	F_score	M_score	RFM_Score	Segment
Customer ID								
14911.0	1	205	129898.30	4	4	4	444	Best Customers
14156.0	14	83	57667.02	4	4	4	444	Best Customers
17850.0	8	155	50623.87	4	4	4	444	Best Customers
13089.0	4	89	35682.65	4	4	4	444	Best Customers
15311.0	1	116	29452.50	4	4	4	444	Best Customers
17841.0	1	90	27560.94	4	4	4	444	Best Customers
13081.0	7	18	23516.42	4	4	4	444	Best Customers
13093.0	9	45	22928.47	4	4	4	444	Best Customers
14298.0	11	34	22073.38	4	4	4	444	Best Customers
14646.0	10	59	19276.98	4	4	4	444	Best Customers


```
# Tính tổng doanh thu theo tháng
df['Month'] = df['InvoiceDate'].dt.month
monthly_sales = df.groupby('Month')['TotalPrice'].sum()

print(monthly_sales)
```


```
Month
1    316184.272
2    317346.906
3    452915.531
4    380919.692
5    388890.540
6    405865.260
7    370542.240
8    355046.090
9    502874.281
10   679995.290
11   754883.052
12   613599.610
Name: TotalPrice, dtype: float64
```

```
# Vẽ biểu đồ doanh thu theo tháng
plt.figure(figsize=(12,6))

monthly_sales.plot(marker='o')

plt.title('Doanh thu hàng tháng')
plt.xlabel('Month')
plt.ylabel('Revenue')
plt.grid(True)

plt.show()
```



-> Nhận xét về Doanh thu hàng tháng:

- Biểu đồ doanh thu hàng tháng cho thấy doanh thu có sự biến động rõ rệt theo từng thời điểm trong năm. Từ kết quả phân tích, có thể nhận thấy một số xu hướng quan trọng như sau:

+ *Doanh thu thấp ở đầu năm*: Trong các tháng 1 và 2, doanh thu ở mức thấp và khá ổn định. Điều này cho thấy nhu cầu mua sắm của khách hàng trong giai đoạn đầu năm chưa cao.

+ *Tăng trưởng vào tháng 3*: Doanh thu tăng mạnh vào tháng 3, cho thấy có thể xuất hiện nhu cầu mua sắm cao hơn hoặc tác động từ các chiến dịch marketing, chương trình khuyến mãi hoặc yếu tố mùa vụ.

+ *Giai đoạn giữa năm tương đối ổn định*: Từ tháng 4 đến tháng 8, doanh thu dao động ở mức trung bình và không có biến động quá lớn. Điều này phản ánh thị trường duy trì trạng thái ổn định trong giai đoạn này.

+ *Tăng trưởng mạnh vào cuối năm*: Từ tháng 9 đến tháng 11, doanh thu tăng mạnh liên tục và đạt đỉnh vào tháng 11. Đây là dấu hiệu rõ rệt của seasonal shopping behavior, có thể liên quan đến các dịp lễ hội, mùa mua sắm cuối năm hoặc các chương trình giảm giá lớn.

+ *Giảm nhẹ vào tháng 12*: Sau khi đạt đỉnh ở tháng 11, doanh thu giảm nhẹ trong tháng 12 nhưng vẫn duy trì ở mức cao hơn nhiều so với phần lớn các tháng còn lại trong năm.

Ý nghĩa kinh doanh:

- Kết quả phân tích cho thấy doanh thu có xu hướng tăng mạnh vào cuối năm. Doanh nghiệp có thể tận dụng insight này để:

- + Tăng cường chiến dịch marketing trong giai đoạn cuối năm
- + Chuẩn bị inventory và logistics trước mùa cao điểm
- + Triển khai chương trình khuyến mãi vào các tháng có nhu cầu cao
- + Tối ưu nguồn lực nhằm đáp ứng lượng đơn hàng tăng mạnh

*Doanh thu theo mùa

```
#Tính tổng doanh thu theo mùa
def get_season(month):
    if month in [12, 1, 2]:
        return 'Đông'
    elif month in [3, 4, 5]:
        return 'Xuân'
    elif month in [6, 7, 8]:
        return 'Hạ'
    else:
        return 'Thu'

df['Season'] = df['Month'].apply(get_season)
```

```
season_sales = df.groupby('Season')['TotalPrice'].sum()

print(season_sales)
```


```
Season
Hạ      1131453.590
Thu     1937752.623
Xuân    1222725.763
Đông    1247130.788
Name: TotalPrice, dtype: float64
```

```
# Vẽ minh họa tổng doanh thu theo mùa
plt.figure(figsize=(8,6))

sns.barplot(
    x=season_sales.index,
    y=season_sales.values
)

plt.title('Doanh thu theo mùa')
plt.xlabel('Season')
plt.ylabel('Revenue')

plt.show()
```



Biểu đồ cho thấy doanh thu mùa Thu cao nhất và vượt trội rõ rệt so với các mùa còn lại, trong khi mùa Hạ thấp nhất. Hai mùa Xuân và Đông có doanh thu khá gần nhau, nằm ở mức trung bình.

© Nhận xét cụ thể:

- + Mùa Thu đạt khoảng 1,9 triệu, cao nhất trong 4 mùa.
- + Mùa Hạ chỉ khoảng 1,1 triệu, thấp nhất.
- + Mùa Xuân và mùa Đông đều quanh mức 1,2–1,25 triệu, chênh lệch không đáng kể.
- + Mức chênh lệch giữa mùa cao nhất và thấp nhất là khá lớn, cho thấy doanh thu có tính mùa vụ rõ rệt.

Ý nghĩa:

- + Doanh nghiệp có thể đang bán tốt hơn vào mùa Thu, có thể do nhu cầu tăng theo thời tiết, lễ hội, hoặc hành vi mua sắm theo mùa.
- + Mùa Hạ có thể là giai đoạn cần tăng khuyến mãi, tối ưu quảng cáo hoặc ra sản phẩm phù hợp hơn để cải thiện doanh thu.
- + Nếu đây là dữ liệu bán hàng theo năm, nên kết hợp thêm số liệu theo tháng để xác định chính xác nguyên nhân biến động.

5. TỔNG KẾT VÀ ĐỀ XUẤT

5.1. Tổng hợp Insight

*** Thị trường và doanh thu**

- United Kingdom chiếm tỷ trọng áp đảo về cả số lượng giao dịch lẫn doanh thu, vượt xa France, Germany và EIRE - phản ánh mức độ phụ thuộc cao vào một thị trường duy nhất, tiềm ẩn rủi ro tập trung (concentration risk).

- Doanh thu có tính mùa vụ rõ rệt: đạt đỉnh vào tháng 11 (mùa Thu / cuối năm), thấp nhất vào mùa Hạ. Xu hướng tổng thể là tăng trưởng đều qua các năm 2009–2011.

- Một số ít sản phẩm chủ lực (như "REGENCY CAKESTAND 3 TIER") chiếm tỷ trọng doanh thu không tương xứng so với toàn danh mục - minh họa rõ nguyên lý Pareto 80/20.

*** Hành vi khách hàng**

- Phần lớn giao dịch có số lượng nhỏ và giá trị đơn hàng thấp (phân phối lệch phải); các đơn hàng lớn mang tính ngoại lệ nhưng đóng góp đáng kể vào tổng doanh thu.

- Tương quan giữa Price và Quantity rất yếu - cho thấy hành vi mua hàng mang tính "nhu cầu" hơn là nhạy cảm về giá.

- Mô hình RFM cho thấy phần lớn khách hàng thuộc nhóm "Others" (tương tác thấp), trong khi nhóm "Best Customers" và "Loyal Customers" tuy ít nhưng đóng vai trò cốt lõi về doanh thu.

- Khách hàng ID 14911 là "Whale Customer" nổi bật với chi tiêu vượt 120.000 đơn vị - gấp hơn 2 lần người đứng thứ hai. Đây vừa là tài sản quý, vừa là điểm rủi ro nếu chỉ phụ thuộc vào một cá nhân này.

5.2 Giá trị thực tiễn

- Giảm tỷ lệ khách hàng rời bỏ

+ Dựa trên RFM score, doanh nghiệp có thể nhận diện sớm các khách hàng có dấu hiệu rời bỏ (Recency tăng cao) để can thiệp kịp thời bằng email voucher hoặc ưu đãi tái tương tác.

- Triển khai loyalty program với ưu đãi cá nhân hóa cho ~200–300 khách hàng VIP thuộc nhóm "Best Customers" và "Loyal Customers" giúp bảo vệ nguồn doanh thu nền tảng. Mục tiêu: giảm 5–7% tỷ lệ churn trong vòng 6 tháng.

- Kích hoạt lại nhóm khách hàng tiềm năng

+ Nhóm "Others" chiếm đa số nhưng chưa được khai thác - đây là nguồn tăng trưởng lớn nếu được tiếp cận đúng cách.

+ Triển khai chuỗi email automation "win-back" gồm 3–5 email được gửi sau 30/60/90 ngày kể từ lần mua cuối, kết hợp đề xuất sản phẩm cá nhân hóa theo lịch sử mua hàng. Mục tiêu: chuyển đổi 10–15% nhóm Others thành Loyal Customers trong 12 tháng.

- Tăng doanh thu theo mùa vụ

+ Bắt đầu chiến dịch marketing từ tháng 8 thay vì chờ đến tháng 10, nhằm "làm ấm" khách hàng trước mùa cao điểm. Đồng thời tăng cường inventory và logistics từ tháng 9 để tránh hết hàng trong tháng 11.

+ Trong giai đoạn thấp điểm (mùa Hạ), triển khai các chương trình khuyến mãi kích cầu để san bằng biến động doanh thu. Mục tiêu: tăng 10–15% doanh thu Q4 so với cùng kỳ.

- Đa dạng hóa thị trường và danh mục sản phẩm

+ France, Germany và Netherlands đã có nền tảng khách hàng nhất định nhưng tỷ trọng còn thấp. Đầu tư vào đa ngôn ngữ, logistics địa phương và chiến dịch quảng cáo riêng cho từng thị trường giúp giảm rủi ro phụ thuộc vào UK. Mục tiêu: nâng tỷ trọng doanh thu ngoài UK lên 25–30%.

+ Xếp hạng sản phẩm theo doanh thu và tần suất mua hàng để cắt giảm các SKU "dead stock", tập trung vào sản phẩm chủ lực và thiết lập cross-sell/upsell. Mục tiêu: cải thiện biên lợi nhuận ròng 3–5%.

5.3 Hạn Chế

- Thiếu thông tin địa lý chi tiết: Dataset chỉ có "Country", không có City hay ZIP Code, nên không thể phân tích vùng nội bộ hay tối ưu logistics theo địa bàn.

-> Đề xuất: bổ sung trường địa chỉ chi tiết vào hệ thống ghi nhận đơn hàng.

- Thiếu dữ liệu nhân khẩu học và kênh tiếp cận: Không biết khách hàng thuộc độ tuổi nào, đến từ kênh nào (organic, paid, referral), nên không thể phân khúc sâu hơn.

-> Đề xuất: tích hợp CRM hoặc form đăng ký để thu thập thêm thông tin.

- Các giao dịch hủy / trả hàng bị loại bỏ hoàn toàn: Mặc dù cần thiết cho phân tích doanh thu, dữ liệu này chứa thông tin quý về tỷ lệ hoàn hàng theo sản phẩm và thị trường.

-> Đề xuất: xây dựng bảng phân tích riêng cho giao dịch trả hàng.

- Dữ liệu chỉ bao gồm 2009–2011: Thị trường bán lẻ trực tuyến đã thay đổi căn bản kể từ đó. Kết quả phù hợp cho mục đích học phương pháp luận, nhưng cần cập nhật dữ liệu thực tế nếu ứng dụng vào kinh doanh hiện nay.

- Mô hình RFM dựa trên ngưỡng thủ công: Việc gán điểm theo rule-based có thể không tối ưu nếu ngưỡng không phản ánh đúng hành vi thực tế. Đề xuất: kết hợp với K-Means Clustering để tự động tìm ngưỡng phân khúc tối ưu.

- Phân tích hiện tại dừng ở mức mô tả (descriptive): Chưa có khả năng dự đoán (predictive) hay đề xuất hành động tối ưu (prescriptive).

5.4 Đề xuất

Dựa trên kết quả phân tích, nhóm đề xuất một số giải pháp nhằm nâng cao hiệu quả kinh doanh như sau:

- Tăng cường chăm sóc khách hàng giá trị cao: Doanh nghiệp nên triển khai loyalty program, ưu đãi cá nhân hóa và các chương trình membership dành cho nhóm Best Customers và Loyal Customers nhằm tăng khả năng giữ chân khách hàng.
- Thực hiện chiến dịch re-engagement: Đối với nhóm khách hàng thuộc “Others”, doanh nghiệp có thể áp dụng email marketing, voucher giảm giá hoặc remarketing để tăng khả năng quay lại mua hàng.
- Tối ưu hoạt động kinh doanh theo mùa: Doanh nghiệp nên tập trung nguồn lực, inventory và chiến dịch marketing vào giai đoạn cuối năm khi nhu cầu mua sắm tăng mạnh.
- Ứng dụng phân tích dữ liệu nâng cao: Trong tương lai, doanh nghiệp có thể áp dụng Machine Learning hoặc Customer Lifetime Value (CLV) để dự đoán hành vi khách hàng và tối ưu chiến lược kinh doanh hiệu quả hơn.